XXIX ENMC XVII ECTM
ENCONTRO NACIONAL DE MODELAGEM COMPUTACIONAL
ENCONTRO DE CIÊNCIA E TECNOLOGIA DE MATERIAIS

INTELIGÊNCIA ARTIFICIAL APLICADA À DETECÇÃO DE CAPRINOS EM AMBIENTE CONFINADO

Vinícius Latini Gonçalves[1], Gabriel Vaz Bernardini Ferreira[2], Felipe Girardi Siqueira[2], Luciana Conceição D. Campos[1], Érica da Costa Reis Carvalho[2], Acir Moreno Soares Júnior[2]

[1]Universidade Federal de Juiz de Fora (UFJF) - Juiz de Fora - MG
[2]Universidade Federal de São João del-Rei (UFSJ) - São João del-Rei - MG

INTRODUÇÃO

O uso de Visão Computacional vem se expandindo na zootecnia de precisão, viabilizando o monitoramento automatizado de animais em confinamento. Contudo, a aplicação de detectores genéricos em condições reais ainda esbarra em variações severas de **perspectiva de captura** (frontal ou superior) e **iluminação** (diurna ou noturna/infravermelho).

Este trabalho propõe uma arquitetura de **Mistura de Especialistas** (*Mixture of Experts* – MoE) para a detecção, com classe única `goat`, de caprinos da raça *Saanen* em ambiente de confinamento na UFSJ. Uma rede de roteamento (*gating network*) baseada em *EfficientNet* classifica exclusivamente o **cenário de captura** – e não o animal – direcionando cada vídeo a um dentre quatro detectores YOLOv8 especializados por combinação de perspectiva e iluminação.

METODOLOGIA

Dataset: vídeos capturados por 4 câmeras fixas (`Cam01`–`Cam04`), 1280×960 px a 8 FPS, ao longo de 36 sessões de gravação (7 dias, rebanho fixo de 8 indivíduos). Rotulação manual (classe única `goat`) com a ferramenta *EasyLabel*, desenvolvida por alunos da UFSJ.

Cenário	Imagens	Caixas	Sessões
Frente Dia	2.022	16.185	8
Frente Noite	2.001	16.008	13
Cima Dia	2.549	18.258	6
Cima Noite	2.032	16.254	9
Total	**8.604**	**66.705**	**36**

Tabela 1 – Caracterização do dataset por cenário operacional

Validação – Temporal K-Fold ($K = 5$): imagens quase-idênticas de vídeo contínuo (8 FPS) causariam vazamento de dados (*leakage*) em um K-Fold aleatório convencional. Adotou-se um particionamento por **blocos temporais contíguos** dentro de cada sessão, com **purge buffer de 15 quadros** nas bordas treino/validação, eliminando quase-duplicatas na fronteira. Auditoria confirmou 0% de sobreposição exata entre treino e validação em todos os *folds*.

Modelo base: YOLOv8m, entrada 640×640 px, até 300 épocas, *batch size* automático, *early stopping* (*patience*=30).

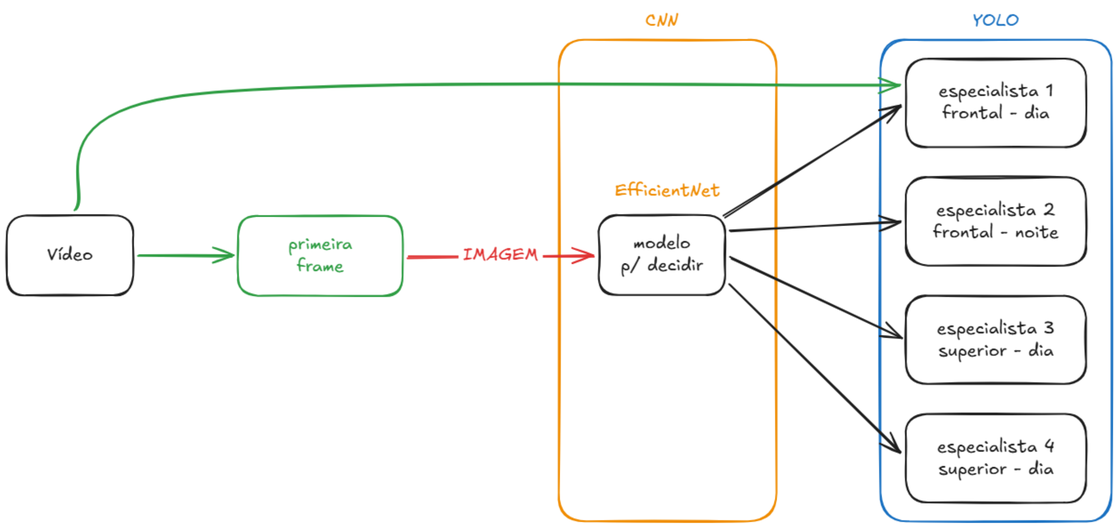


Figura 1 – Arquitetura MoE: roteamento por cenário + 4 especialistas YOLOv8

RESULTADOS

Rede de roteamento (*gating network*): convergência em 9 épocas, Precisão/Revocação/*F1-Score* $= 1{,}00$ em 272 imagens de teste. Análise de *Occlusion* mostrou que padrões do ambiente (parede, cercado) são determinantes para a classificação do cenário, robusta a variações de iluminação.

Especialistas YOLOv8 (melhor *fold*): desempenho elevado e consistente nos 4 cenários, com mAP_{50} saturado em $0{,}9950$.

Modelo	F1	mAP50	mAP50-95
Frontal Dia	0,9971	0,9950	0,9015
Frontal Noite	0,9970	0,9950	0,8821
Superior Dia	0,9997	0,9950	0,8645
Superior Noite	0,9975	0,9950	0,8338
Baseline (Overall)	**0,9953**	**0,9948**	**0,8773**

Tabela 2 – Especialistas MoE vs. baseline monolítico (YOLOv8m único, dataset unificado, mesmo protocolo K-Fold)

Nas métricas agregadas, o baseline monolítico (YOLOv8m treinado na união dos 4 cenários) iguala-se aos especialistas – o ganho da MoE **não está no mAP bruto**, e sim em: **(i) modularidade** (novo cenário = novo especialista, sem retreinar o todo); **(ii) isolamento de falhas** por cenário; **(iii) explicabilidade** do roteamento via *Occlusion*.

Evidência qualitativa (contagem de caixas em inferência, 4 vídeos-teste, 80 quadros, 8 indivíduos/quadro = 640 esperadas):

Cenário	Overall	MoE	Esperado
Frente Dia	623	**640**	640
Frente Noite	643	**640**	640
Cima Dia	532	**640**	640
Cima Noite	663	**640**	640

Tabela 3 – MoE acerta 100% da contagem esperada nos 4 vídeos; baseline sub/sobredetecta

O baseline monolítico subdetecta em *Cima Dia* (oclusão entre indivíduos agrupados) e sobredetecta em *Cima/Frente Noite* (caixas duplicadas com $IoU = 0{,}64$, abaixo do limiar de NMS). O especialista MoE correspondente acerta as 640 caixas em todos os 4 cenários, com confiança média de $0{,}91$ (variação $0{,}74$–$0{,}96$).

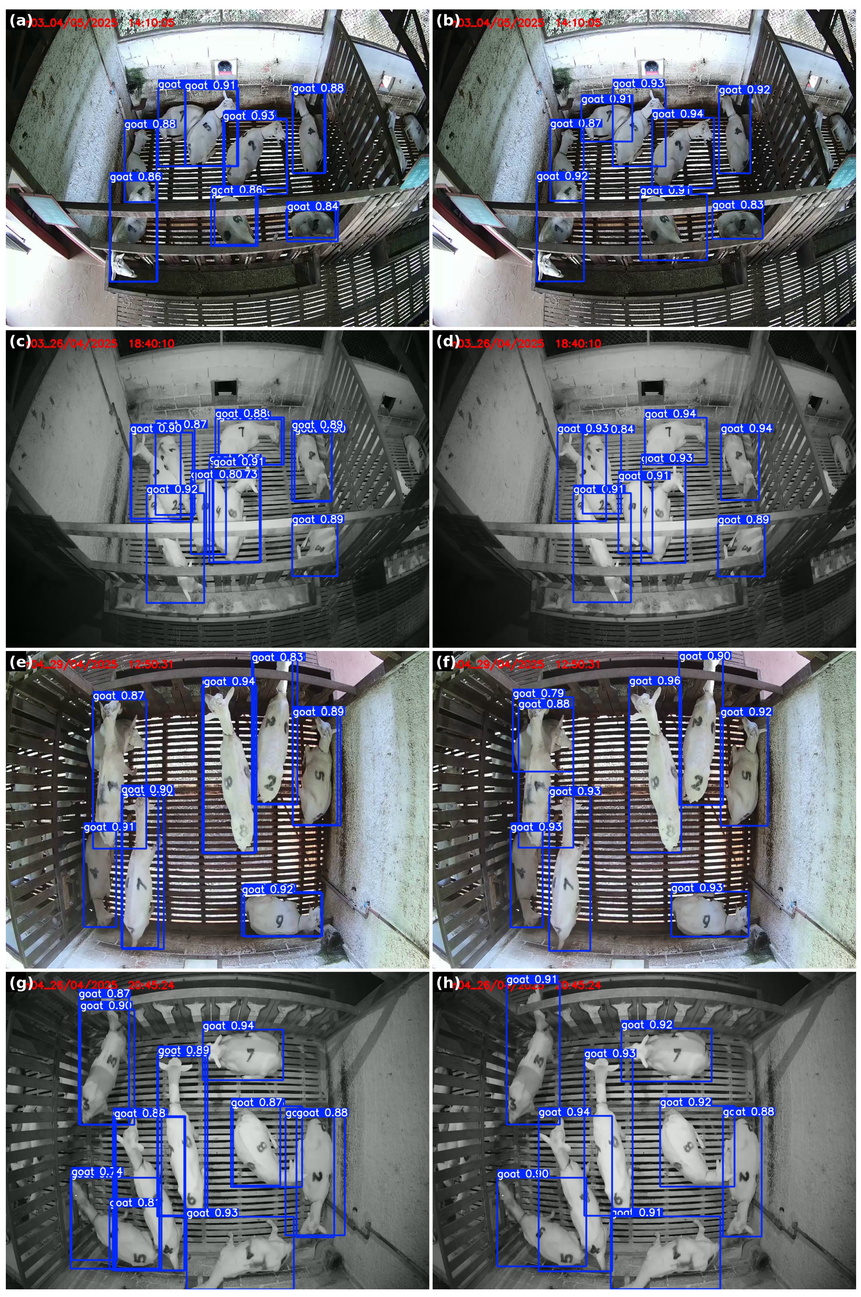


Figura 2 – Baseline (esq.) vs. especialista MoE (dir.) no mesmo quadro: (a-b) Frente Dia, (c-d) Frente Noite, (e-f) Cima Dia, (g-h) Cima Noite

CONCLUSÕES

A arquitetura MoE proposta apresentou desempenho elevado e consistente na detecção de caprinos nos quatro cenários de perspectiva/iluminação avaliados. Embora as métricas agregadas de detecção não demonstrem superioridade da MoE sobre o baseline monolítico, a inspeção qualitativa em vídeo evidencia maior estabilidade da contagem de indivíduos por especialista, além das vantagens estruturais de **modularidade**, **isolamento de falhas** e **explicabilidade** do roteamento.

Trabalhos futuros: rastreamento individualizado dos animais (*multi-object tracking*) para análise comportamental de bem-estar animal; expansão do ecossistema com novos especialistas para cenários adicionais, sem retreinar os demais.

AGRADECIMENTOS

Os autores agradecem à Universidade Federal de Juiz de Fora (UFJF), à Universidade Federal de São João del-Rei (UFSJ) e ao Departamento de Zootecnia da UFSJ pelo suporte no desenvolvimento deste trabalho.